

Usando o **plantR** para atualizar informações entre duplicatas

Renato A. F. de Lima (raffima at usp.br)

20 July 2021

Sumário

1	Introdução	1
2	Obtendo os registros	2
2.1	Baixando os registros do speciesLink e GBIF	2
2.2	Unindo os registros	2
3	Padronização e validação de campos relevantes	2
3.1	Padronização das informações	3
3.2	Validação das informações padronizadas	3
4	Preparando os registros para a busca de duplicatas	5
4.1	Definindo os identificadores únicos	5
4.2	Definindo os campos a serem usados na busca	5
5	Obtendo as indicações de duplicatas	6
5.1	Inspecionando os resultados de número de duplicatas encontradas	6
6	Homogeneizando as informações entre grupos de duplicatas	7
6.1	Inspecionando os resultados da homogeneização	7
7	Preparando os dados para a atualização da coleção	7
7.1	Filtrando campos para atualização de coleções ou de sua base de dados	7
7.1.1	Qual são os registros da coleção que podem/devem ser atualizadas?	7
7.2	Atualização taxonômica	8
7.2.1	Quais campos podem ser usados na atualização taxonômica?	8
7.2.2	Algum nome não encontrado ou com notas em relação à Flora do Brasil?	8
7.2.3	Alguma atualização taxonômica feita nas duplicatas em outras coleções?	9
7.2.4	Salvando os resultados da atualização taxonômica	12
7.3	Atualização de coordenadas geográficas	12
7.4	Atualização de informações de localidade	12

1 Introdução

Esse tutorial foi pensado para auxiliar curadores de herbário que pretendem atualizar suas coleções usando informações oriundas de duplicatas depositadas em outras coleções. Como realizar esse processo para a coleção inteira demandaria obter as bases de dados de todas as coleções biológicas, os códigos abaixo foram preparados para serem executados por famílias individualmente.

Agradecimentos especiais ao André L. de Gasper pelos testes do pacote e pela sugestão de criar esse tutorial mais dirigido aos curadores de herbário.

2 Obtendo os registros

Antes de começar precisamos carregar o pacote usando a função `library()`, assumindo que você tem o pacote instalado junto ao seu R. Se você ainda não tem o pacote instalado em seu computador, siga as instruções do tutorial geral do pacote (i.e. `'plantr_tutorial.html'`).

```
library("plantR")
```

2.1 Baixando os registros do speciesLink e GBIF

Iremos usar a família *Blechnaceae* para esse exemplo, e baixando dados tanto do speciesLink (INCT) quanto do GBIF. O GBIF possui mais de 430,000 registros para a família no mundo todo. Assumindo que o curador seja de uma coleção do Brasil, iremos baixar apenas as coletas realizadas no Brasil (i.e. campo `country` igual a `'BR'`).

Para downloads do GBIF, o limite do número de registros baixados é controlado pelo argumento `n.records` e o padrão é baixar até 5000 registros por item buscado. Então o limite foi modificado para baixar mais registros. Contudo, há um limite do número máximo de 100,000 registros que podem ser baixados de um só vez. Por isso, iremos baixar apenas os registros da família para o Brasil ($<100,000$). Veja o help da função `rgbif2()` para sugestões sobre como fazer para famílias com mais de 100,000 registros no GBIF.

Note que o campo `species` da função `rgbif2()` aceita não apenas nomes ao nível de espécie, mas em qualquer nível taxonômico. Para a função `rspeciesLink()`, há um campo específico para o nome da família (i.e. `family`).

```
familia <- "Blechnaceae"
occs_splink <- rspeciesLink(family = familia)
occs_gbif <- rgbif2(species = familia,
                    country = "BR",
                    n.records = 450000)
dim(occs_splink)
```

```
## [1] 24201    51
```

```
dim(occs_gbif)
```

```
## [1] 23212    166
```

Foram encontrados aproximadamente 24,000 registros para a família no speciesLink e aprox. 23,000 registros para o Brasil no GBIF.

2.2 Unindo os registros

Em seguida, combinamos os registros dos dois repositórios em apenas um objeto usando a função `formatDwc()` e removendo colunas desnecessárias para a busca de duplicatas:

```
occs <- formatDwc(splink_data = occs_splink,
                 gbif_data = occs_gbif, drop = TRUE)
dim(occs)
```

```
## [1] 47413    47
```

Veja que o objeto `occs` contém agora a soma dos registros vindos do speciesLink e GBIF (i.e. aprox. 47,000 em Abril de 2021).

3 Padronização e validação de campos relevantes

Mesmo que você esteja interessado apenas em atualizar um tipo de informação (e.g. nome da espécie), é importante padronizar a notação e formato de campos que são importantes para a busca de duplicatas. Essa

padronização não é perfeita, mas ela aumenta as chances de recuperar duplicatas com pequenas diferenças de notação em campos como nome e número do coletor, a localidade da coleta, nome da família e a grafia e/ou formato do nome da espécie.

3.1 Padronização das informações

O pacote **plantR** possui funções que executam várias dessas edições de uma só vez. As funções `formatOcc()`, `formatLoc()`, `formatCoord()` e `formatTax()` fazem a padronização dos campos relacionados à coleta em si (e.g. código da coleção, nome e número do coletor), à localidade da coleta, às coordenadas geográficas associadas à coleta e à informação taxonômica.

A verificação ortográfica e de sinônimos via o The Plant List é relativamente demorada. Portanto, iremos fazer a conferência e validação dos nomes apenas usando a Flora do Brasil (i.e. campo `db` igual a 'fbo')

```
occs <- formatOcc(occs)
occs <- formatLoc(occs)
occs <- formatCoord(occs)
occs <- formatTax(occs, db = "fbo")
```

```
## The following family names were automatically replaced:
```

```
##
## |Genus          |Old fam.    |New fam.      |
## |:-----|:-----|:-----|
## |Blechnum       |Blechnaceae |Acanthaceae   |
## |Didymoglossum |Blechnaceae |Hymenophyllaceae |
## |Phyllitis      |Blechnaceae |Aspleniaceae  |
## |Pteris         |Blechnaceae |Pteridaceae   |
```

Note que as funções não editam as colunas originais dos registros. Elas criam novas colunas que armazenam as informações editadas que em geral têm o mesmo nome da coluna original seguido do sufixo 'new'.

3.2 Validação das informações padronizadas

Para cada conjunto de duplicatas, a tomada de decisão de qual espécimen será usado para obter a informação válida ou a mais atual sobre localidade, coordenadas geográficas ou identificação taxonômica depende de um processo de validação. Esse processo de validação não é essencial para encontrar as duplicatas entre coleções, mas ela ajuda no processo de tomada de decisão sobre qual é a melhor informação disponível.

Assim como para a padronização dos campos, o pacote **plantR** oferece funções que executam essas validações de uma só vez. As funções `validateLoc()` e `validateCoord()` fazem a validação dos campos de localidade e coordenadas geográficas, respectivamente.

```
occs <- validateLoc(occs)
```

```
## [1] "Locality resolution in the original data vs. edited data:"
```

```
##
## original
## edited country locality municipality no_info
## country 4640 234 8 0
## locality 10 6122 1 0
## municipality 2 23511 3697 0
## no_info 7 7 2 74
## stateProvince 0 7522 208 0
##
## original
## edited stateProvince
## country 34
## locality 0
## municipality 0
```

```
## no_info 0
## stateProvince 1334
```

```
occs <- validateCoord(occs)
```

A função `validateTax()` faz uma classificação da confiabilidade da identificação taxonômica dos registros. Essa avaliação é feita em uma base global de nomes de taxonomistas por família (veja o help da função digitando `?validateTax` no seu console do R).

Contudo, essa base de dados não é completa. Assim, pode ser importante executar a função de maneira preliminar para avaliar se não há nomes de taxonomistas que sejam relevantes à essa avaliação e que não estejam na base de dados. Vamos portanto visualizar os 15 nomes com mais determinações para a família usado no exemplo, e que não estão listados na base de dados como especialistas da família:

```
temp <- validateTax(occs, top.det = 15)
## Top people with many determinations but not in the taxonomist list:
##
## |Identifier          | Records|
## |-----|-----:|
## |Gonzatti, F.        | 1146|
## |Matos, F.B.         | 937|
## |Almeida, T.E.       | 849|
## |Pietrobon, M.R.     | 838|
## |Kazmirczak, C.      | 681|
## |Prado, J.           | 589|
## |Sehnem, A.          | 498|
## |(uc, A.R.S.         | 466|
## |Senna, R.M.         | 442|
## |Smith, A.R.         | 431|
## |Moran, R.C.         | 391|
## |Mickel, J.T.        | 381|
## |Athayde Filho, F.P. | 333|
## |Michelon, C.        | 321|
## |Pietrobon-Silva, M.R. | 315|
rm(temp)
```

Note que entre os nomes listados há vários especialistas do grupo, mas que não são exatamente especialistas da família em questão (e.g. 'Gonzatti, F.'). Outros nomes podem estar listados porque a base de dados usada está incompleta.

Para incluir nomes faltantes de taxonomistas, é possível usar o campo `miss.taxonomist`. Nesse exemplo vamos incluir dois nomes 'Kazmirczak, C.' e 'Prado, J.', que têm que ser fornecidos em um formato específico: nome da 'família + underline + nome do determinador.

```
falta.tax <- paste(familia, c("Kazmirczak, C.", "Prado, J."), sep = "_")
occs <- validateTax(occs, miss.taxonomist = falta.tax,
                    top.det = 15)
## Top people with many determinations but not in the taxonomist list:
##
## |Identifier          | Records|
## |-----|-----:|
## |Gonzatti, F.        | 1146|
## |Matos, F.B.         | 937|
## |Almeida, T.E.       | 849|
## |Pietrobon, M.R.     | 838|
## |Sehnem, A.          | 498|
## |(uc, A.R.S.         | 466|
```

```
## |Senna, R.M.          |      442|
## |Smith, A.R.         |      431|
## |Moran, R.C.         |      391|
## |Mickel, J.T.        |      381|
## |Athayde Filho, F.P. |      333|
## |Michelon, C.        |      321|
## |Pietrobom-Silva, M.R. |      315|
## |Caxambu, M.G.       |      295|
## |Barros, I.C.L.      |      289|
```

Note que agora os nomes incluídos já não são mais listados entre os nomes com mais identificações, mas que não são especialistas da família.

4 Preparando os registros para a busca de duplicatas

4.1 Definindo os identificadores únicos

Para a busca de duplicatas, precisamos de algumas informações adicionais. Uma delas é ter um identificador único para cada registro (i.e. número de tombo). Para isso podemos concatenar o código padronizado da coleção e seu número de registro ou tombo na coleção correspondente. Isso pode ser feito usando a função `getTombo()`:

```
occs$numTombo <- getTombo(occs[, "collectionCode.new"],
                        occs[, "catalogNumber"])
```

Como muitas coleções têm suas bases de dados tanto no speciesLink/INCT quanto no GBIF é normal termos números de tombo repetidos nos dados, as chamadas duplicatas virtuais. Como nosso interesse é pelas informações contidas nas duplicatas físicas entre coleções, é indicado remover números de tombo repetidos. Isso não afeta a busca por duplicatas, mas simplifica a sua checagem final, isto é, as duplicatas virtuais não estarão entre as duplicatas encontradas.

Como alguns registros não têm número de tombo (tombo igual a 'US_NA'), usamos o código abaixo para realizar a remoção apenas dos números de tombo repetidos:

```
dim(occs)[1]

## [1] 47413

occs <- occs[!duplicated(occs$numTombo) |
              grepl("_NA$", occs$numTombo, perl = TRUE),]
dim(occs)[1]

## [1] 31777
```

Note que cerca de um terço dos registros representavam duplicatas virtuais.

Note também que existe a possibilidade de coleções terem um mesmo número de tombo para registros diferentes, devido a algum tipo de erro. Mas após o código acima, não estamos mais considerando esse tipo de erro.

4.2 Definindo os campos a serem usados na busca

Uma informação essencial para a busca de duplicatas é a definição de quais campos serão usados na busca por duplicatas. No **plantR** é possível usar qualquer combinação dos campos contendo a informação do nome da família ou espécie, nome ou sobrenome do coletor, número do coletor, ano de coleta e localidade da coleta.

Como há muita variação de notação entre coleções no nome do coletor, é possível usar apenas o seu sobrenome. Além disso, como o uso apenas do sobrenome e número de coletor pode retornar falsas duplicatas para nomes

muito comuns e números de coletor baixos (e.g. Lima 10), é aconselhado incluir outros campos na busca. Neste exemplo iremos usar três combinações de campos, que são geradas usando a função `prepDup()`:

```
dups <- prepDup(occs,
  comb.fields = list(c("species", "col.name", "col.number"),
    c("col.last.name", "col.number", "col.loc"),
    c("col.last.name", "col.number", "col.year")))
```

Note que salvamos os strings concatenados de busca em uma tabela à parte, pois essa informação não será necessária após a busca, evitando aumentar ainda mais o número de novas colunas.

Note também que o padrão da função é não incluir na busca por duplicatas registros com informação faltante de coletor, data ou localidade, etc. Se você quiser incluir esses registros o campo `ignore.miss` deverá ser modificado de `TRUE` para `FALSE`. Mas tome cuidado pois isso pode resultar em muitas falsas duplicatas!!

5 Obtendo as indicações de duplicatas

Finalmente, podemos usar a nova tabela gerada para buscar os registros com alguma indicação de serem um mesmo espécimen com material depositado em diferentes coleções.

```
dups <- getDup(dups)
head(dups[order(dups$dup.ID),], 4)
##          numTombo          dup.srch.str1
## 8219 ALCB_56777      Blechnum_Loureiro, D.M._501
## 8275 ALCB_1518 Blechnum occidentale_Loureiro, D.M._501
## 2464 JPB_49351      Blechnum binervatum_Gomes, L.A._95
## 2494 ASE_21027 Neoblechnum brasiliense_Gomes, L.A._95
##          dup.srch.str2  dup.srch.str3 dup.numb
## 8219 Loureiro_501_ilheus Loureiro_501_2001      2
## 8275 Loureiro_501_ilheus Loureiro_501_2001      2
## 2464      Gomes_95_capela      Gomes_95_2011      2
## 2494      Gomes_95_capela      Gomes_95_2011      2
##          dup.prop          dup.ID
## 8219 0.666666666666667 [ALCB_1518|ALCB_56777]
## 8275 0.666666666666667 [ALCB_1518|ALCB_56777]
## 2464 0.666666666666667 [ASE_21027|JPB_49351]
## 2494 0.666666666666667 [ASE_21027|JPB_49351]
```

5.1 Inspeccionando os resultados de número de duplicatas encontradas

Novas colunas foram criadas. A coluna ‘dup.prop’ contém a força de indicação das duplicatas (i.e. quanto mais próximo de 1 mais segurança na indicação). Vamos inspecionar as categorias geradas:

```
table(dups$dup.prop)
##
##          0 0.333333333333333 0.666666666666667
##        11825          1130          3459
##          1          cc
##        10237          5126
```

Em seguida, precisamos reunir as colunas de interesse da busca de duplicatas com a nossa planilha geral:

```
occs <- cbind.data.frame(occs,
  dups[,c("dup.ID", "dup.numb", "dup.prop")],
  stringsAsFactors = FALSE)
```

Para esses dados, cerca de 27% dos registros possuem forte indicação de duplicatas e cerca de 38% não tiveram nenhuma indicação (i.e. prováveis unicatas). Além desses, 16% foram classificados com ‘dup.prop’ > 0.5 (e.g. 2 sobre 3 combinações iguais) e como ‘cc’ de ‘cannot check’ por falta de informações associadas aos campos escolhidos. Para registros com ‘dup.prop’ < 0.5 (apenas 1 combinação em comum) sugere-se um ‘pente-fino’, pois esses casos podem representar problemas ou falsas duplicatas.

6 Homogeneizando as informações entre grupos de duplicatas

Por fim, podemos usar para todas as duplicatas de cada grupo as informações mais confiáveis ou recentes sobre os registros. Atualmente, o **plantR** faz essa homogeneização para as informações de localidade, coordenadas geográficas e/ou taxonomia. Ela é feita usando a função `mergeDup()` cujo padrão é fazer apenas o merge para registros com ‘dup.prop’ > 0.75. Isso pode ser alterado usando o campo `prop` da função, como abaixo.

```
occs <- mergeDup(occs, prop = 0.65)
```

O default dessa função usa os campos já editados pelo **plantR** e cria novas colunas com um ‘1’ adicionado ao final do nome da coluna (e.g. coluna ‘family.new’ após a homogeneização será armazenada na nova coluna ‘family.new1’). Lembre-se, contudo, que os nomes das colunas que serão usadas podem ser definidas pelo usuário (e.g. usar a coluna ‘family’ ao invés da ‘family.new’).

6.1 Inspeccionando os resultados da homogeneização

Podemos comparar as mudanças obtidas para um dos campos, como por exemplo, o campo que define o nível de confiança na identificação do registro. Note que mais de cerca de 700 registros que possuíam nível definido como ‘unknown’ e ‘low’ passaram a ter um nível definido como ‘high’.

```
table(occs$tax.check, occs$tax.check1, dnn = c("antes", "depois"))
##           depois
## antes      high    low unknown
##   high     5890     0         0
##   low       609 13571     0
##   unknown   283     0    11424
```

7 Preparando os dados para a atualização da coleção

7.1 Filtrando campos para atualização de coleções ou de sua base de dados

Para esse tutorial, vamos supor que o André L. de Gasper, atual curador do herbário FURB, queira comparar os materiais depositados no FURB com as demais coleções. Mais especificamente, ele quer atualizar as informações relacionadas à identificação taxonômica e aos campos de determinação.

7.1.1 Qual são os registros da coleção que podem/devem ser atualizadas?

Primeiro, precisamos definir o nome da coleção focal e filtrar quais registros possuem direta ou indiretamente informações que podem ser relevantes. No caso, iremos definir o FURB como a coleção focal.

```
colecacao <- "FURB"
occs1 <- occs[grepl(colecacao, occs$numTombo, perl = TRUE) |
              grepl(colecacao, occs$dup.ID, perl = TRUE), ]
dim(occs1)
## [1] 1762 103
```

Podemos inspecionar quantos registros há por coleção:

```
table(occs1$collectionCode.new)
##
```

##	ALCB	ASE	BHCB	BHCB-SL	CESJ	CGMS	CRI
##	2	1	18	18	23	1	15
##	CTBS	EAFM	EVb	FCAB	FLOR	FPS	FUEL
##	1	1	6	7	37	20	21
##	FURB	HAS	HCF	HEPH	HSTM	HUCS	HURB
##	1286	1	28	11	2	70	22
##	IRAI	JOI	LUSC	MBM	MO	NX	NY
##	1	43	2	38	1	3	1
##	PACA	RB	RON	SAMES	SHPR	SLUI	UEC
##	2	32	1	4	7	10	2
##	UPCB	VIC	VIES				
##	13	7	4				

Note que há cerca de 1700 registros de Blechnaceae no nosso filtro, dos quais aprox. 1300 são de registros do FURB mesmo, e o restante dos registros estão espalhados em cerca de 40 outras coleções.

Se você quiser fazer o mesmo, mas para outra coleção basta trocar o nome da coleção que é atribuída ao objeto chamado `colecacao`.

7.2 Atualização taxonômica

7.2.1 Quais campos podem ser usados na atualização taxonômica?

Podemos filtrar apenas as colunas que são de interesse para a checagem alvo que o André quer realizar, a checagem taxonômica. Para cada um dos campos de interesse iremos filtrar as informações básicas de cada registro, mais a informação original (em formato DwC), a editada pelo **plantR** (sufixo ‘new’) e a homogeneizada a partir dos grupos de duplicatas (sufixo ‘new1’) relativas à identificação taxonômica dos registros.

Note que como usamos os defaults do **plantR** os filtros das colunas também seguem esse padrão. Caso você tenha selecionado outras colunas, os nomes abaixo têm que ser adaptados.

```
colunas <- c("numTombo", "recordedBy.new", "recordNumber.new",
            "identifiedBy", "identifiedBy.new", "identifiedBy.new1",
            "yearIdentified", "yearIdentified.new", "yearIdentified.new1",
            "family", "family.new", "family.new1",
            "scientificName", "scientificName.new", "scientificName.new1",
            "scientificNameStatus", "tax.notes",
            "tax.check", "tax.check1", "dup.ID")
occs1.tax <- occs1[, colunas]
```

7.2.2 Algum nome não encontrado ou com notas em relação à Flora do Brasil?

```
table(occs1[grepl("FURB_", occs1$numTombo, fixed = TRUE) &
        !occs1$tax.notes %in% "", c("scientificName", "tax.notes")])
##                                     tax.notes
## scientificName                     not found
## Blechnum xcaudatum Cav.              0
## Blechnum xleopoldense (Dutra) V.A.O.Dittrich & Salino 0
## Blechnum australe L.                  2
## Lomaridium acutum (Desv.) Gasper & V.A.O.Dittrich    1
##                                     tax.notes
## scientificName                     was misspelled
## Blechnum xcaudatum Cav.              14
## Blechnum xleopoldense (Dutra) V.A.O.Dittrich & Salino 1
```



```
## Blechnum australe L. 0
## Lomaridium acutum (Desv.) Gasper & V.A.O.Dittrich 0
```

Sem grandes problemas para o FURB! Algumas notas em relação à diferença como os híbridos são anotados na Flora do Brasil e duas espécies que não ocorrem no Brasil.

7.2.3 Alguma atualização taxonômica feita nas duplicatas em outras coleções?

Para realizar essa operação, podemos realizar uma filtragem mais, para ficarmos apenas com os registros com indicações de duplicata (i.e. coluna 'dup.ID' não vazia):

```
occs2.tax <- occs1.tax[!is.na(occs1.tax$dup.ID), ]
occs2.tax <- occs2.tax[order(occs2.tax$dup.ID), ]
```

Para facilitar o trabalho do curador, podemos marcar as duplicatas com indicação de alteração da identificação:

```
occs2.tax$checar.taxon <-
  !is.na(occs2.tax$scientificName.new) &
  occs2.tax$scientificName.new != occs2.tax$scientificName.new1 &
  grepl("FURB_", occs2.tax$numTombo, fixed = TRUE)
occs2.tax[occs2.tax$checar.taxon,]
##      numTombo  recordedBy.new recordNumber.new
## 10560 FURB_41754 Falkenberg, D.B.           6416
## 10587 FURB_6461 Falkenberg, D.B.           6416
## 2520  FURB_35038  Schmitt, J.L.           3169
## 2559  FURB_6656  Schmitt, J.L.           3169
## 2302  FURB_6463  Gonzatti, F.             597
##      identifiedBy identifiedBy.new identifiedBy.new1
## 10560  A.L. de Gasper  Gasper, A.L.  Gasper, A.L.
## 10587  Gasper, AL de  Gasper, A.L.  Gasper, A.L.
## 2520  A.L. de Gasper  Gasper, A.L.  Gasper, A.L.
## 2559  Gasper, A.L. de  Gasper, A.L.  Gasper, A.L.
## 2302  Dittrich, V.A.O. Dittrich, V.A.O. Dittrich, V.A.O.
##      yearIdentified yearIdentified.new yearIdentified.new1
## 10560             <NA>             2010             2010
## 10587             <NA>             2010             2010
## 2520             <NA>             2016             2017
## 2559             <NA>             n.d.             2017
## 2302             <NA>             2018             2018
##      family  family.new family.new1
## 10560 Blechnaceae Blechnaceae Blechnaceae
## 10587 Blechnaceae Blechnaceae Blechnaceae
## 2520  Blechnaceae Blechnaceae Blechnaceae
## 2559  Blechnaceae Blechnaceae Blechnaceae
## 2302  Blechnaceae Blechnaceae Blechnaceae
##
##                                scientificName
## 10560                                Blechnum auriculatum Cav.
## 10587                                Blechnum auriculatum Cav.
## 2520  Lomaria spannagelii (Rosenst.) Gasper & V.A.O.Dittrich
## 2559  Lomaria spannagelii (Rosenst.) Gasper & V.A.O.Dittrich
## 2302                                Blechnum L.
##
##      scientificName.new  scientificName.new1
## 10560 Blechnum auriculatum  Blechnum australe
## 10587 Blechnum auriculatum  Blechnum australe
## 2520  Lomaria spannagelii Parablechnum cordatum
```

```
## 2559 Lomaria spannagelii Parablechnum cordatum
## 2302 Blechnum Blechnum xleopoldense
## scientificNameStatus tax.notes tax.check tax.check1
## 10560 name_w_authors high high
## 10587 name_w_authors high high
## 2520 name_w_authors high high
## 2559 name_w_authors high high
## 2302 indet/name_w_authors high high
##
## dup.ID
## 10560 BHCBSL_28997/BHCBSL_28997/FLOR_23621/FUEL_19780/FURB_41754/FURB_6461
## 10587 BHCBSL_28997/BHCBSL_28997/FLOR_23621/FUEL_19780/FURB_41754/FURB_6461
## 2520 FLOR_17332/FURB_35038/FURB_6656/JOI_11850
## 2559 FLOR_17332/FURB_35038/FURB_6656/JOI_11850
## 2302 FUEL_53109/FURB_39824/FURB_6463/HUCS_39468/SLUI_4389/SLUI_4389.0/VIC_37877/VIES_27594
## checar.taxon
## 10560 TRUE
## 10587 TRUE
## 2520 TRUE
## 2559 TRUE
## 2302 TRUE
```

Note que há cinco registros cujo nome encontrado do FURB é diferente do nome encontrado nas demais coleções. Vamos imprimir um exemplo para entender o que as funções estão fazendo. Iremos usar como exemplo o identificador de duplicatas ('dup.ID') 'FUEL_53109|FURB_39824|FURB_6463|HUCS_39468|SLUI_4389|VIC_37877|VIES_27594'.

```
occs2.tax[grepl('FURB_6463', occs2.tax$dup.ID),]
## numTombo recordedBy.new recordNumber.new
## 2259 FURB_39824 Gonzatti, F. 597
## 2260 HUCS_39468 Gonzatti, F. 597
## 2265 VIES_27594 Gonzatti, F. 597
## 2266 SLUI_4389 Gonzatti, F. 597
## 2290 VIC_37877 Gonzatti, F. 597
## 2294 FUEL_53109 Gonzatti, F. 597
## 2302 FURB_6463 Gonzatti, F. 597
## 31711 SLUI_4389.0 Gonzatti, F. 597
## identifiedBy identifiedBy.new identifiedBy.new1
## 2259 V.A.O. Dittrich Dittrich, V.A.O. Dittrich, V.A.O.
## 2260 Gonzatti, F. Gonzatti, F. Dittrich, V.A.O.
## 2265 Gonzatti, F. Gonzatti, F. Dittrich, V.A.O.
## 2266 <NA> s.n. Dittrich, V.A.O.
## 2290 <NA> s.n. Dittrich, V.A.O.
## 2294 Dittrich, VAO Dittrich, V.A.O. Dittrich, V.A.O.
## 2302 Dittrich, V.A.O. Dittrich, V.A.O. Dittrich, V.A.O.
## 31711 <NA> s.n. Dittrich, V.A.O.
## yearIdentified yearIdentified.new yearIdentified.new1
## 2259 <NA> 2018 2018
## 2260 <NA> 2019 2018
## 2265 <NA> 2012 2018
## 2266 <NA> n.d. 2018
## 2290 <NA> n.d. 2018
## 2294 <NA> 2018 2018
## 2302 <NA> 2018 2018
## 31711 <NA> n.d. 2018
## family family.new family.new1
```

```

## 2259 Blechnaceae Blechnaceae Blechnaceae
## 2260 Blechnaceae Blechnaceae Blechnaceae
## 2265 Blechnaceae Blechnaceae Blechnaceae
## 2266 Blechnaceae Blechnaceae Blechnaceae
## 2290 Blechnaceae Blechnaceae Blechnaceae
## 2294 Blechnaceae Blechnaceae Blechnaceae
## 2302 Blechnaceae Blechnaceae Blechnaceae
## 31711 Blechnaceae Blechnaceae Blechnaceae
##                                     scientificName
## 2259 Blechnum xleopoldense (Dutra) V.A.O.Dittrich & Salino
## 2260 Blechnum xleopoldense (Dutra) V.A.O.Dittrich & Salino
## 2265 Blechnum xleopoldense (Dutra) V.A.O.Dittrich & Salino
## 2266                                     Blechnum australe L.
## 2290                                     Blechnaceae
## 2294 Blechnum xleopoldense (Dutra) V.A.O.Dittrich & Salino
## 2302                                     Blechnum L.
## 31711                                     Blechnum australe
##             scientificName.new    scientificName.new1
## 2259 Blechnum xleopoldense Blechnum xleopoldense
## 2260 Blechnum xleopoldense Blechnum xleopoldense
## 2265 Blechnum xleopoldense Blechnum xleopoldense
## 2266     Blechnum australe Blechnum xleopoldense
## 2290     Blechnaceae sp. Blechnum xleopoldense
## 2294 Blechnum xleopoldense Blechnum xleopoldense
## 2302     Blechnum Blechnum xleopoldense
## 31711    Blechnum australe Blechnum xleopoldense
##             scientificNameStatus    tax.notes
## 2259 hybrid_species/name_w_authors was misspelled
## 2260 hybrid_species/name_w_authors was misspelled
## 2265 hybrid_species/name_w_authors was misspelled
## 2266             name_w_authors    not found
## 2290             family_as_genus
## 2294 hybrid_species/name_w_authors was misspelled
## 2302             indet/name_w_authors
## 31711             possibly_ok    not found
##             tax.check tax.check1
## 2259             high    high
## 2260             low    high
## 2265             low    high
## 2266             unknown    high
## 2290             unknown    high
## 2294             high    high
## 2302             high    high
## 31711             unknown    high
##
##                                     dup.ID
## 2259 FUEL_53109/FURB_39824/FURB_6463/HUCS_39468/SLUI_4389/SLUI_4389.0/VIC_37877/VIES_27594
## 2260 FUEL_53109/FURB_39824/FURB_6463/HUCS_39468/SLUI_4389/SLUI_4389.0/VIC_37877/VIES_27594
## 2265 FUEL_53109/FURB_39824/FURB_6463/HUCS_39468/SLUI_4389/SLUI_4389.0/VIC_37877/VIES_27594
## 2266 FUEL_53109/FURB_39824/FURB_6463/HUCS_39468/SLUI_4389/SLUI_4389.0/VIC_37877/VIES_27594
## 2290 FUEL_53109/FURB_39824/FURB_6463/HUCS_39468/SLUI_4389/SLUI_4389.0/VIC_37877/VIES_27594
## 2294 FUEL_53109/FURB_39824/FURB_6463/HUCS_39468/SLUI_4389/SLUI_4389.0/VIC_37877/VIES_27594
## 2302 FUEL_53109/FURB_39824/FURB_6463/HUCS_39468/SLUI_4389/SLUI_4389.0/VIC_37877/VIES_27594
## 31711 FUEL_53109/FURB_39824/FURB_6463/HUCS_39468/SLUI_4389/SLUI_4389.0/VIC_37877/VIES_27594

```

```
##      checar.taxon
## 2259      FALSE
## 2260      FALSE
## 2265      FALSE
## 2266      FALSE
## 2290      FALSE
## 2294      FALSE
## 2302       TRUE
## 31711     FALSE
```

Para esse caso há identificações feitas por diferentes pessoas e em diferentes datas. Como descrito no tutorial do **plantR**, o registro com identificação mais recente feita por um especialista da família é usado como a identificação de referência - nesse caso, a identificação feita por ‘Dittrich, V.A.O.’ em 2018.

O registro ‘FURB_6463’, assim como o ‘SLUI_4389’ e o ‘VIC_37877’, possuem identificações diferentes e estes tiveram suas informações homogeneizadas automaticamente pelo **plantR** (colunas terminando em ‘.new1’) e podem ser usadas pelo curador do FURB para atualização.

7.2.4 Salvando os resultados da atualização taxonômica

Em seguida, podemos salvar os resultados em uma planilha à parte para conferência, usando a função `saveData()`:

```
nome.arquivo <- paste(colecao, familia, "taxonomia", sep = "_")
saveData(occs2.tax,
         file.name = nome.arquivo,
         dir.name = "checagem_plantR",
         file.format = "csv", compress = FALSE)
```

Esses registros estão marcados como ‘TRUE’ na coluna ‘checar.taxon’ que foi salva na pasta ‘checagem_plantR’ do seu diretório local. Por fins de organização, usamos a combinação do nome da família e da coleção no nome do arquivo ‘.csv’ salvo localmente.

7.3 Atualização de coordenadas geográficas

[EM BREVE]

7.4 Atualização de informações de localidade

[EM BREVE]